

Del software de sistemas al análisis léxico

Repaso de las notas 02 y 03 y trabajo con el Cuadernillo 02

Manuel Soto Romero Araceli Liliana Reyes Cabello


Colegio de Ciencia y Tecnología, UACM

Semestre 2026-2

Iniciamos con Kahoot

Iniciamos con el Kahoot

Ruta de trabajo



Durante la sesión

Alternaremos el repaso de las notas 02 y 03 con el trabajo del **Cuadernillo de ejercicios 02.**

Abrimos la caja del compilador



La descripción externa no basta

En su interior, el compilador reconoce unidades, descubre estructuras, comprueba restricciones y transforma representaciones antes de producir su salida.

El programa cambia de representación, pero debe conservar su significado.


Dos grandes etapas: análisis y síntesis

Análisis

Examina el programa fuente para reconocer sus componentes, su estructura y las restricciones que debe satisfacer.

Síntesis

Toma la representación obtenida por el análisis y construye una representación equivalente en el lenguaje destino.



Las fases se comunican mediante contratos

Fase	Entrada	Salida principal
Análisis léxico	Caracteres	Secuencia de tokens
Análisis sintáctico	Tokens	Representación estructurada
Análisis semántico	Estructura e información necesaria	Representación comprobada
Generación de IR	Representación comprobada	Representación intermedia
Optimización	Representación intermedia	Representación equivalente
Generación de código	Representación validada o intermedia	Programa destino

Pregunta para cada fase


¿Qué recibe?, ¿qué tarea realiza?, ¿qué produce? y ¿quién utiliza el resultado?

Cuadernillo de ejercicios 02

Ejercicios 1 y 2

- ▶ **Esencial — Ejercicio 1:** reconocer los contratos entre fases.
- ▶ **Extensión — Ejercicio 2:** distinguir las tareas de análisis y de síntesis.

Tres fases para comprender el programa fuente



- ▶ El léxico reconoce unidades elementales.
- ▶ El sintáctico organiza esas unidades según la gramática.
- ▶ El semántico comprueba restricciones como declaraciones y compatibilidad de tipos.

Cada fase detecta problemas diferentes

Fase	Situación que le corresponde
Léxica	Ningún patrón permite reconocer el inicio de los caracteres restantes.
Sintáctica	Los tokens existen, pero no pueden organizarse de acuerdo con la gramática.
Semántica	La estructura es válida, pero incumple una regla de declaración o de tipos.

Límite de responsabilidad


Reconocer un texto como identificador no permite decidir todavía si fue declarado ni qué tipo tiene.

Cuadernillo de ejercicios 02

Ejercicios 3 y 4


- ▶ **Esencial — Ejercicio 3:** decidir qué fase debe responder en cada situación.
- ▶ **Extensión — Ejercicio 4:** revisar los límites de responsabilidad entre fases.

De la representación validada al código destino



- ▶ Una IR facilita la comunicación y la transformación del programa.
- ▶ La optimización busca una mejora sin cambiar el comportamiento definido.
- ▶ No todos los compiladores usan exactamente una IR o el mismo número de optimizaciones.

El compilador del curso y la cadena posterior




Destino de nuestro compilador

El programa C completa la traducción prevista para el curso. Todavía necesita un compilador de C para continuar la cadena hacia un ejecutable.

En clase construiremos la base IMP; en las prácticas la extenderemos para IMP++.

Integrar significa acordar interfaces



Contrato

La fase consumidora debe conocer la forma y el significado de los datos que recibe.

Cambio

Si cambia una representación, deben revisarse las fases que la producen y la consumen.


ASA significa *árbol de sintaxis abstracta*; la denominación proviene del inglés *Abstract Syntax Tree*, abreviado AST.

Cuadernillo de ejercicios 02

Ejercicios 5 y 6

- ▶ **Esencial — Ejercicio 5:** completar el recorrido común de IMP/IMP++ a C.
- ▶ **Extensión — Ejercicio 6:** analizar las interfaces y el efecto de sus cambios.

Función del analizador léxico



- ▶ Agrupa caracteres en lexemas y produce tokens.
- ▶ Puede omitir espacios o comentarios cuando el lenguaje indica que no son significativos.
- ▶ Conserva atributos necesarios para las fases posteriores.
- ▶ No determina por sí solo la estructura completa, las declaraciones o los tipos.

Del flujo de caracteres a los tokens

Fragmento ilustrativo: no define la sintaxis de IMP

```
valor = valor + inc;
```

Lexema	Clasificación	Resultado descriptivo
valor	identificador	ID(valor)
=	asignación	ASIG
valor	identificador	ID(valor)
+	suma	SUMA
inc	identificador	ID(inc)
;	terminador	PYC

Token, lexema y patrón

Patrón


Describe la forma que pueden tener los lexemas asociados con un nombre de token.

Lexema


Es la secuencia concreta de caracteres reconocida en el programa fuente.

Token

Comunica un nombre de token y un valor de atributo opcional.



¿Para qué sirve un atributo?



Mismo nombre, distinta aparición

El nombre ENTERO comunica la categoría; el atributo distingue el valor concreto. De manera semejante, un token ID puede conservar el texto del identificador o una referencia a información asociada.


Algunos operadores y signos de puntuación no necesitan atributo: su nombre ya comunica la información requerida.

Cuadernillo de ejercicios 02

Ejercicios 7 y 8

- ▶ **Esencial — Ejercicio 7:** relacionar token, lexema, patrón y atributo.
- ▶ **Esencial — Ejercicio 8:** analizar el fragmento ilustrativo `total = 25;`.

El analizador sintáctico solicita tokens



Una interfaz frecuente

El analizador léxico consume sólo los caracteres necesarios para reconocer el siguiente lexema y devolver su token.

La salida léxica debe tener la forma que espera el analizador sintáctico.

Qué especificamos y qué apoya Lark

El equipo especifica

- ▶ qué categorías reconoce el lenguaje;
- ▶ qué forma tiene cada categoría;
- ▶ qué información debe conservar cada token.

Lark apoya

- ▶ la lectura de la entrada;
- ▶ el reconocimiento según las reglas dadas;
- ▶ la producción de tokens para observar o analizar.

```
parser=None    lexer="basic"    lex()
```

Esta configuración permite observar el analizador léxico de manera independiente.

Primero la usaremos para construir el lexer de IMP; la práctica extenderá sus reglas para IMP++.

Confusiones que debemos evitar


Confusión	Corrección
Lexema y patrón son lo mismo.	El lexema es concreto; el patrón describe una forma.
El léxico recibe tokens y produce caracteres.	Recibe caracteres y produce tokens.
Dos tokens ID tienen el mismo lexema.	Pueden compartir nombre y tener lexemas y atributos distintos.
La optimización repara la sintaxis.	Transforma una representación válida sin cambiar su comportamiento.
El C generado ya es ejecutable.	Debe continuar por un compilador de C.
Lark decide las categorías del lenguaje.	Lark aplica las categorías y reglas especificadas por el equipo.

Cuadernillo de ejercicios 02

Ejercicios 9 y 10

- ▶ **Esencial — Ejercicio 9:** completar la comunicación para solicitar el siguiente token.
- ▶ **Extensión — Ejercicio 10:** detectar y corregir confusiones del repaso completo.

Conclusión



Idea de cierre

El compilador organiza transformaciones mediante fases con responsabilidades e interfaces claras. El análisis léxico inicia el recorrido interno: reconoce lexemas, produce tokens y comunica la información que necesita la fase sintáctica.

Cada contrato se implementará primero para IMP y se extenderá después para IMP++.

Referencias

1. Soto Romero, M. y Reyes Cabello, A. L. (2026). *Programación de Sistemas. Nota de clase 02: Estructura y fases de un compilador*. Colegio de Ciencia y Tecnología, UACM.
2. Soto Romero, M. y Reyes Cabello, A. L. (2026). *Programación de Sistemas. Nota de clase 03: Fundamentos del análisis léxico*. Colegio de Ciencia y Tecnología, UACM.
3. Soto Romero, M. y Reyes Cabello, A. L. (2026). *Programación de Sistemas. Cuadernillo de ejercicios 02: Del software de sistemas al análisis léxico*. Colegio de Ciencia y Tecnología, UACM.
4. Aho, A. V., Lam, M. S., Sethi, R., y Ullman, J. D. (2008). *Compiladores: principios, técnicas y herramientas* (2.^a ed.). Pearson Educación. ISBN 978-970-26-1133-2.
5. Thain, D. (2026). *Introduction to Compilers and Language Design* (2.^a ed.). University of Notre Dame.
6. Vilar Torres, J. M. (2010). *Estructura de los compiladores e intérpretes*. Universitat Jaume I.
7. Vilar Torres, J. M. (2010). *Analizador léxico*. Universitat Jaume I.